Организационные моменты

Прокопьева Мария Артуровна

Бакалавриат: Психология (НИУ ВШЭ) ’23

Магистратура: Data Science (НИУ ВШЭ) ’25

Центр языка и мозга НИУ ВШЭ

tg: https://t.me/maria_prokopeva

mail: protopovamaria@gmail.com

План занятий

Дата	Тема	Тип занятия
14.01.2025	Введение в R	Лекция + семинар
	Визуализация данных	Лекция + семинар (дз1)
21.01.2025	Описательная статистика, нормальное распределение, сравнение средних, гипотезы	Лекция + семинар
	Параметрические и непараметрические методы сравнения средних (t-test, ANOVA, M-U, Kruskal_Wallis)	Лекция + семинар (дз2)
28.01.2025	Корреляционный анализ и Линейная регрессия	Лекция
	Корреляционный анализ и Линейная регрессия	Семинар (дз3)
04.02.2025	Множественная линейная регрессия	Лекция
	Множественная линейная регрессия	Семинар (дз4)

План занятий

Дата	Тема	Тип занятия
11.02.2025	Логистическая регрессия	Лекция
	Логистическая регрессия	Семинар (дз5)
18.02.2025	Линейные модели со смешанными эффектами	Лекция
	Линейные модели со смешанными эффектами	Семинар (дз6)
25.02.2025	Линейные модели со смешанными эффектами	Лекция
	Линейные модели со смешанными эффектами	Семинар
04.03.2025	Презентация проектов	Семинар
	Презентация проектов	Семинар

Оценивание

- Домашние задания
- Проект
- Бонусы за квизы / участие в экспериментах

Ссылка на гит-хаб репозиторий с материалами по курсу:

https://github.com/mariaprotopova/R-DataAnalysis_2026/

План занятий

- Разбор ДЗ
- Лекция
- Семинар


R
Studio®

RStudio File Edit Code View Plots Session Build Debug Profile Tools Window Help

Flights - RStudio

Go to file/function | Addins | Flights

flights-example.R

Source on Save | Run | Source

```
1  library(nycflights13)     ## package containing flights dataset
2  library(lubridate)
3  library(dplyr)
4  library(ggplot2)
5
6  head(flights, n = 3)
7  daily <- flights %>%
8    mutate(date = make_date(year, month, day)) %>%
9    count(date) %>%
10   mutate(wday = wday(date, label = TRUE))
11 head(daily, n = 3)
12 ggplot(daily, aes(wday, n)) +
13   geom_boxplot(outlier.colour = "hotpink") +
14   labs(x = "Weekday", y = "Flights",
15        subtitle = "Number of 2013 New York Flights Each Weekday")
16
```

1:1 (Top Level) R Script

Environment | History | Connections | Tutorial

Import Dataset | 346 MiB | List

R | Global Environment

Data

daily | 365 obs. of 3 variables

```
$ date: Date[1:365], format: "2013-01-01" "2013-01-02" …
$ n   : int [1:365] 842 943 914 915 720 832 933 899 902…
$ wday: Ord.factor w/ 7 levels "Sun"<"Mon"<"Tue"<..: 3 …
```

Console | Terminal | Jobs

~/Documents/Flights/

```
# A tibble: 3 x 19
   year month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time arr_delay carrier
  <int> <int> <int>    <int>          <int>     <dbl>    <int>          <int>     <dbl> <chr>
1  2013     1     1      517            515         2      830            819        11 UA
2  2013     1     1      533            529         4      850            830        20 UA
3  2013     1     1      542            540         2      923            850        33 AA
# … with 9 more variables: flight <int>, tailnum <chr>, origin <chr>, dest <chr>, air_time <dbl>,
#   distance <dbl>, hour <dbl>, minute <dbl>, time_hour <dttm>
> daily <- flights %>%
+   mutate(date = make_date(year, month, day)) %>%
+   count(date) %>%
+   mutate(wday = wday(date, label = TRUE))
> head(daily, n = 3)
# A tibble: 3 x 3
  date           n wday
  <date>     <int> <ord>
1 2013-01-01   842 Tue
2 2013-01-02   943 Wed
3 2013-01-03   914 Thu
> ggplot(daily, aes(wday, n)) +
+   geom_boxplot(outlier.colour = "hotpink") +
+   labs(x = "Weekday", y = "Flights",
+        subtitle = "Number of 2013 New York Flights Each Weekday")
>
```

Files | Plots | Packages | Help | Viewer

Zoom | Export

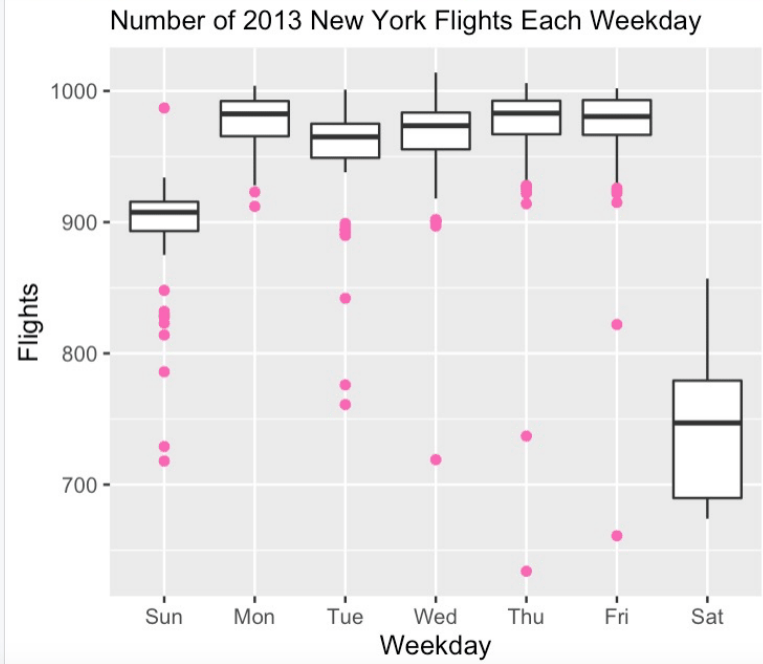

Basics

Названия переменных

1) Выбирайте краткие и понятные названия переменных
2) Название не должно начинаться с числа
3) Не используйте в названии пунктуацию, кроме точки (.), тире (-), подчеркивания (_)
4) Не используйте пробелы в названии
5) Соблюдайте однородность в коде *(varname, VARNAME, var.name, var_name, VarName)*

Basics

Символ	Значение
=	Присвоение
<-	Присвоение
==	Равно
!=	Не равно
< (>)	Больше (меньше)
<= (>=)	Больше (меньше) или равно
%in%	Совпадают ли значения? Входит ли значение в набор (список/кортеж) других значений (TRUE / FALSE)?
|	Логическое ИЛИ
&	Логическое И

Errors

1) Не бойтесь читать описания ошибок
2) Проверьте, загрузили ли вы все библиотеки
3) R чувствителен к регистру: *View() vs. view()*
4) Проверьте раскладку: *c() vs. c()*
5) Проверьте очепятки
6) One line at a time
7) Не бойтесь гуглить ошибки
8) Не бойтесь задавать «глупые» вопросы и просить о помощи :)

```
> dat <- read.csv("data.csv")
Error in file(file, "rt") : cannot open the connection
In addition: Warning message:
In file(file, "rt") :
  cannot open file 'data.csv': No such file or directory
>
```

Stack Overflow
3 answers · 11 years ago

Error: unexpected symbol/input/string constant/numeric ...

These **errors** mean that the **R** code you are trying to run or source is not syntactically correct. That is, you have a typo. Read more

3 answers · Top answer: These errors mean that the R code you are trying to run or source is not synt…

Error: unexpected symbol in: R error message - Stack ... 1 answer May 24, 2018

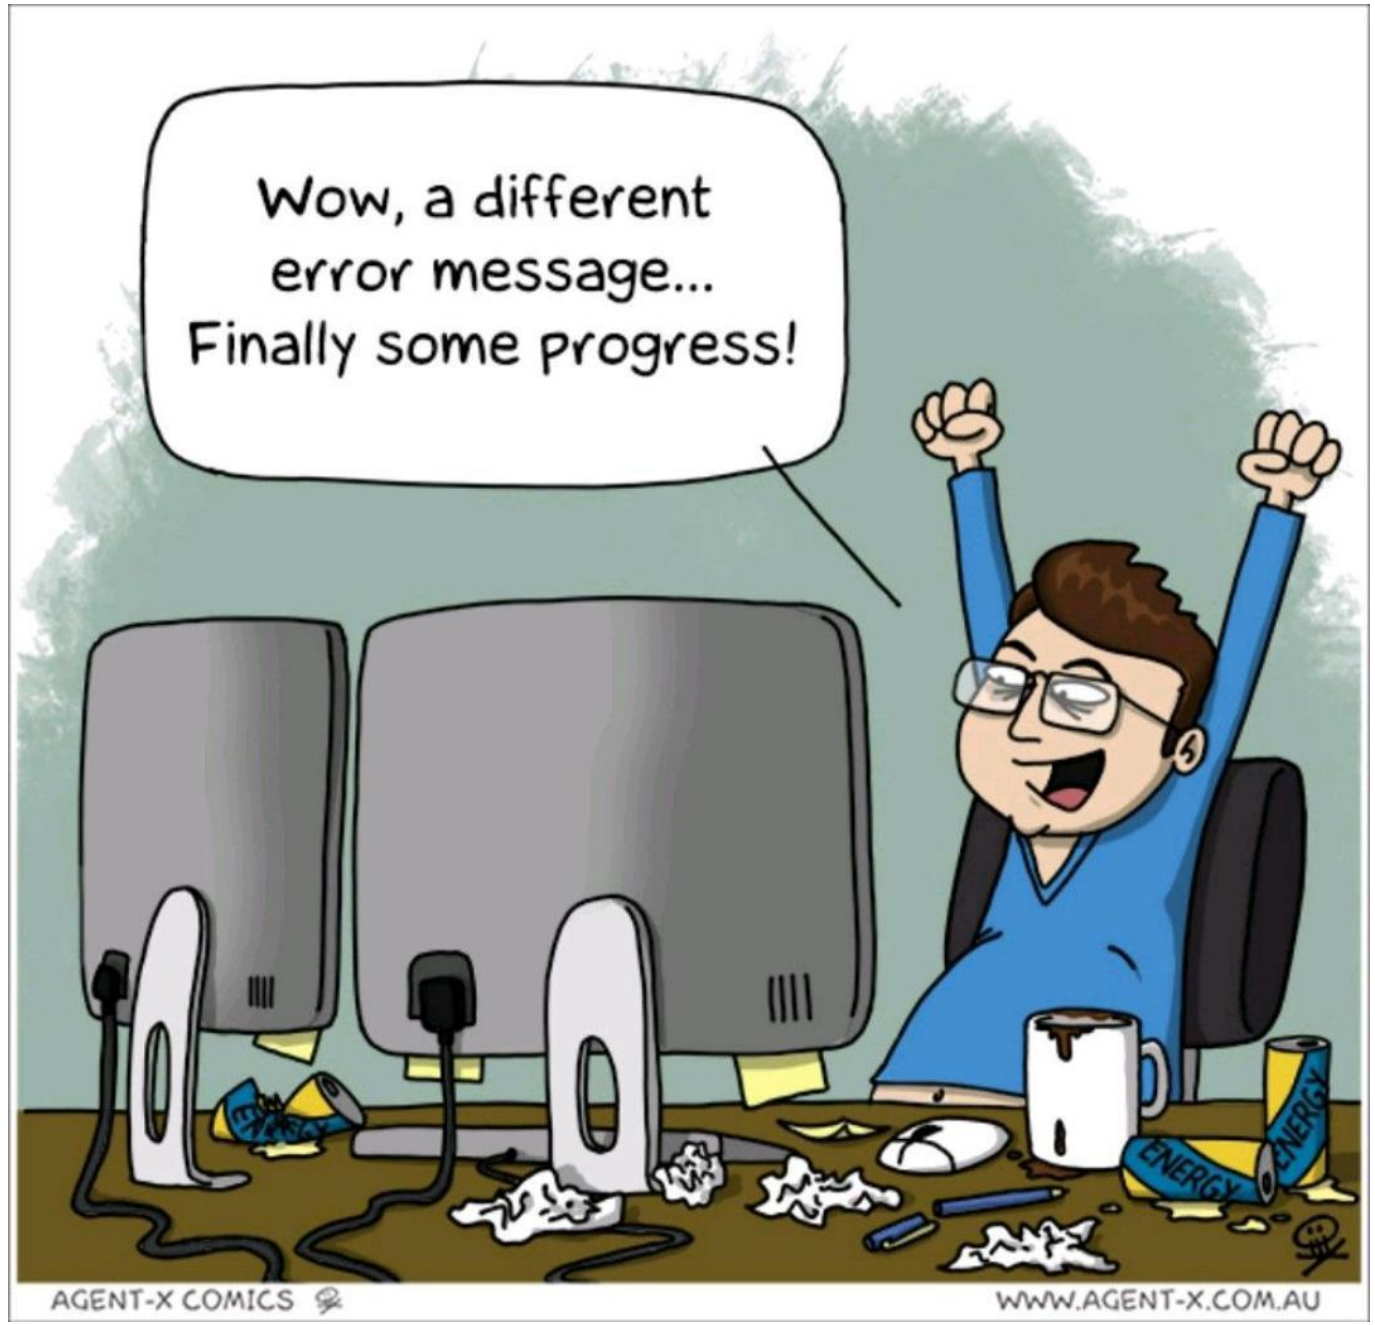
Wow, a different error message... Finally some progress!
ENERGY
ENERGY
AGENT-X COMICS
WWW.AGENT-X.COM.AU

Типы данных

Типы данных

Тип данных – характеристика данных, которая определяет множество допустимых значений и набор операций, которые можно с ними осуществлять

Типы данных

Номинальные – данные представляют собой категории, для которых не применимо упорядочивание

НЕ можем ответить на вопрос: Что больше? На сколько больше? Во сколько раз больше?

Например: имя (Ваня, Николь, Пнина), место рождения (Москва, Антананариву, Самарканд), должность (сис.админ, завлаб, водитель)

Типы данных

Порядковые – значения являются дискретными упорядоченными категориями, т.е. порядок категорий имеет смысл.

2-1 != 5-4

Можем ответить на вопрос: Что больше?

НЕ можем ответить на вопрос: На сколько больше? Во сколько раз больше?

Например: уровень образования (среднее, высшее, кандидат наук), шкала Ликерта

Типы данных

Интервальные – шкала, в которой мы можем численно выразить и сравнить разницу между значениями

Истинного нуля в этой шкале не существует. Любой 0 относителен

2-1 = 5-4

Можем ответить на вопрос: на сколько больше?

Например: градусы Цельсия, годы

Типы данных

Шкала отношений – упорядоченные значения, разница между соседними значениями фиксирована, существует абсолютный ноль.

2-1 = 5-4

Можем ответить на вопросы: на сколько больше/меньше? Во сколько больше/меньше?

Например: градусы по Фаренгейту, метр, грамм

Шкала	Описание	Данные	Операции
Номинативная	Категории (без порядка)	качественные	=, ≠
Порядковая	Упорядоченные категории		=, ≠, >, <
Интервальная	Есть относительный ноль	количественные	=, ≠, >, <, +, -
Шкала отношений	Есть абсолютный ноль		=, ≠, >, <, +, -, *, /

Типы данных в R

- numeric: 1, 3.14, -0.777778
- logical: TRUE, FALSE
- character: “*i <3 R programming language*”
- factor – это строковые данные, которые хранятся в виде чисел, так как содержат небольшое количество уникальных значений → используются для задания групп в данных

Структуры данных

Структура	R	Пример
вектор	**c**()	**c**(1,2,3)
список	**list**()	**list**(1, TRUE, “stuff”)
матрица	**matrix**()	**matrix**(**c**(1,2,3,4), ncol=2) **matrix**(**c**(1,2,3,4), nrow=1)
датафрейм	**data.frame**()	**data.frame**(name=**c**(“Маша”, “Bob”), age=**c**(25, 28), city=**c**(”Москва”, “Springfield”))
	tibble::tibble()	**tibble**(age = **sample**(18:60, size = 30), group = **ifelse**(age > 40, 'old', 'young'))

Data management

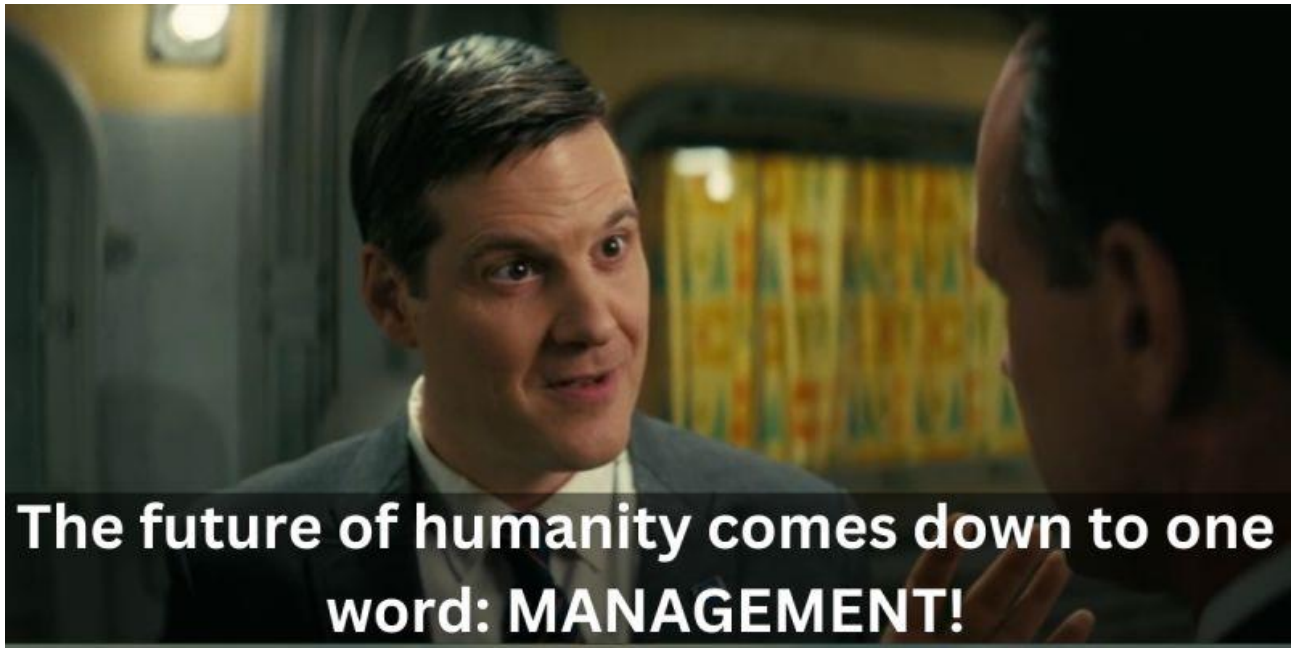

Импорт данных

```
read_csv("path/to/file") # для чтения классических csv-файлов
read_csv2("path/to/file") # для чтения csv-файлов с разделителем точка в запятой
read_delim("path/to/file", delim = "...") # для чтения файлов с любым разделителем
```

```
raw01 <- readxl::read_xlsx('data/data_sharexp/01.xlsx', 2)
```

Смотрим на данные

- **View**()
- **str**()
- **head**()
- **tail**()
- **nrow**()
- **ncol**()

library(tidyverse)

- Pipe (%>%) – оператор, который передает в качестве первого аргумента то, что стоит слева, в функцию, которая стоит справа

```
> sum(5, 6)
[1] 11
> 5 %>% sum(6)
[1] 11
```

```
> sqrt(abs(log(abs(round(sin(1 / cos(3)), 2)), 3)))
[1] 0.3846181
> 3 %>% cos() %>%
+     `/`(1, .) %>%
+     sin() %>%
+     round(2) %>%
+     abs() %>%
+     log(3) %>%
+     abs() %>%
+     sqrt()
[1] 0.3846181
```

```
data[data$train_test=='TEST',] %>%
  group_by(
    latency_class,
    duration_class,
    subject,
    N_repetition,
    N_training,
    decimation
    ) %>%
  summarize(
    percent_corr = mean(percent_corr)
    ) %>%
  ungroup() -> data_mean
```

library(tidyverse)

- **select**()
- **rename**()
- **sapply**()
- **lapply**()
- **filter**()
- **mutate**()

Соединение датасетов

- **left_join()** – левый датасет остается полностью, к нему присоединяются строки правого датасета, соответствующие условию
- **right_join()** – правый датасет остается полностью, к нему присоединяются строки левого датасета, соответствующие условию
- **full_join()** – остаются все строки обоих датасетов, а те, которым не нашлось соответствия в одном из датасетов, ставится NA
- **inner_join()** – остаются только те строки обоих датасетов, которым нашлось соответствие
- **anti_join()** – остаются только те строки обоих датасетов, которым не нашлось соответствие

Группировка и агрегация данных

Агрегация данных – объединение данных по группам и подсчет каких-то показателей внутри каждой группы

- **group_by**()
- **ungroup**()
- **summarize**()

Широкий и длинный форматы

Чаще всего, мы сталкиваемся с данными в таком виде, что по строкам идут наблюдения, а по столбцам – переменные. Такой формат данных называется *широким* (потому что переменных может быть много). В *длинном* формате есть столбец идентификатора, столбец переменных и столбец значений этих переменных

- **pivot_longer**()
- **pivot_wider**()

Wide Data Format

Every value is unique in first column

Groups	Lab	Theory
A	25	60
B	21	55
C	14	49
D	22	69

The values in First column repeat

Long Data Format

Groups	Variable	Values
A	Lab	25
B	Lab	21
C	Lab	14
D	Lab	22
A	Theory	60
B	Theory	55
C	Theory	49
D	Theory	69

Практика на занятии

Using the diamonds built-in dataset (requires **tidyverse**), perform the following tasks:

1) View all the variable names in diamonds.
2) Create a new variable named salePrice to reflect a discount of $250 off of the original cost of each diamond
3) Remove the x, y, and z variables from the diamonds dataset
4) Determine the number of diamonds there are for each cut value
5) Create a new variable called Acceptable with yes or no values using ifelse(). For a yes value, the following criteria must be met:
   - Carat <= 0.8 and Depth > 62
   - Carat > 1