

Анализ главных компонент

Principal Component Analysis (PCA)

Проклятие размерности

По мере увеличения количества размерностей (или признаков) точки (наблюдения) быстро «убегают» друг от друга. Чем больше размерность пространства, в котором находятся точки, тем пустыннее окрестности этих точек.



Экскурс в матрицу. Откуда берется проклятие размерности (curse of dimensionality)?

- (1) Возьмем единичный отрезок, поделим его на отрезки длиной ε . Сколько таких отрезков получится?

Экскурс в матрицу. Откуда берется проклятие размерности (curse of dimensionality)?

- (1) Возьмем единичный отрезок, поделим его на отрезки длиной ε . Сколько таких отрезков получится? $1/\varepsilon$

Экскурс в матрицу. Откуда берется проклятие размерности (curse of dimensionality)?

- (1) Возьмем единичный отрезок, поделим его на отрезки длиной ε . Сколько таких отрезков получится? $1/\varepsilon$
- (2) Возьмем единичный квадрат и поделим его на квадратики со стороной ε . Сколько получится таких квадратов?

Экскурс в матрицу. Откуда берется проклятие размерности (curse of dimensionality)?

- (1) Возьмем единичный отрезок, поделим его на отрезки длиной ε . Сколько таких отрезков получится? $1/\varepsilon$
- (2) Возьмем единичный квадрат и поделим его на квадратики со стороной ε . Сколько получится таких квадратов? $1/\varepsilon^2$

Экскурс в матрицу. Откуда берется проклятие размерности (curse of dimensionality)?

- (1) Возьмем единичный отрезок, поделим его на отрезки длиной ε . Сколько таких отрезков получится? $1/\varepsilon$
- (2) Возьмем единичный квадрат и поделим его на квадратики со стороной ε . Сколько получится таких квадратов? $1/\varepsilon^2$
- (3) Проделаем то же с единичным кубом. Сколько получится кубиков?

Экскурс в матрицу. Откуда берется проклятие размерности (curse of dimensionality)?

- (1) Возьмем единичный отрезок, поделим его на отрезки длиной ε . Сколько таких отрезков получится? $1/\varepsilon$
- (2) Возьмем единичный квадрат и поделим его на квадратики со стороной ε . Сколько получится таких квадратов? $1/\varepsilon^2$
- (3) Проделаем то же с единичным кубом. Сколько получится кубиков? $1/\varepsilon^3$

Экскурс в матрицу. Откуда берется проклятие размерности (curse of dimensionality)?

- (1) Возьмем единичный отрезок, поделим его на отрезки длиной ε . Сколько таких отрезков получится? $1/\varepsilon$
- (2) Возьмем единичный квадрат и поделим его на квадратики со стороной ε . Сколько получится таких квадратов? $1/\varepsilon^2$
- (3) Проделаем то же с единичным кубом. Сколько получится кубиков? $1/\varepsilon^3$

В общем случае, их будет $1/\varepsilon^d$, где d – размерность пространства

Dimension n Volume

1	1	2
2	2	3.14
3	3	4.1888
4	4	4.9348
5	5	5.2638
6	6	5.1677
7	7	4.7248
8	8	4.0587
9	9	3.2985
10	10	2.5502

R = 1


$$V_n(R) = \frac{\pi^{n/2}}{\Gamma(\frac{n}{2} + 1)} R^n$$

20	20	0.0258
	⋮	
100	100	1.8683×10^{-40}
	⋮	
1,000	1,000	8.1691×10^{-2100}
	⋮	

Almost Vanished
≠ 0

Проклятие размерности

По мере увеличения количества размерностей (или признаков) точки (наблюдения) быстро «убегают» друг от друга. Чем больше размерность пространства, в котором находятся точки, тем пустыннее окрестности этих точек.



→ Если хотим исследовать больше переменных, нужно *экспоненциально* больше данных

Экскурс в матрицу. Откуда берется проклятие размерности (curse of dimensionality)?

TL;DR: при увеличении размерности (с ростом количества признаков) точки начинают “разбегаться”. High-dimensional spaces are "empty"

Чем помогает PCA?

Анализ главных компонент (Principal component analysis, PCA)

Цель PCA – уменьшить размерность данных таким образом, чтобы потерять минимальное количество информации. Вместо большого числа исходных переменных получаем меньшее число компонент, рассчитанных на основе исходных переменных

Важно: каждая исходная переменная вносит вклад в расчет каждого фактора! (То есть PCA не производит *отбор* признаков). Меняется только *вес* переменной в расчете фактора (ака *факторная нагрузка*)

Анализ главных компонент (Principal component analysis, PCA)

Мы хотим найти такую линейную комбинацию наших данных, у которой дисперсия максимальна. То есть мы переводим наши данные в новую систему координат.

Возьмем это трехмерное пространство и попробуем найти три таких направления, для которых дисперсия данных максимальна

Анализ главных компонент (Principal component analysis, PCA)


Мы хотим найти такую линейную комбинацию наших данных, у которой дисперсия максимальна. То есть мы переводим наши данные в новую систему координат.



Возьмем это трехмерное пространство и попробуем найти три таких направления, для которых дисперсия данных максимальна

Анализ главных компонент (Principal component analysis, PCA)

Мы хотим найти такую линейную комбинацию наших данных, у которой дисперсия максимальна. То есть мы переводим наши данные в новую систему координат.




Возьмем это трехмерное пространство и попробуем найти три таких направления, для которых дисперсия данных максимальна

Анализ главных компонент

(Principal component analysis, PCA)

Мы хотим найти такую линейную комбинацию наших данных, у которой дисперсия максимальна. То есть мы переводим наши данные в новую систему координат.





Возьмем это трехмерное пространство и попробуем найти три таких направления, для которых дисперсия данных максимальна.

Размерность не стала меньше, но некоторые компоненты менее важны, чем другие (меньше дисперсия)

Анализ главных компонент (Principal component analysis, PCA)

Другая интуиция: если у нас в данных есть связанные переменные, может, они отражают какую-то одну скрытую переменную с разных сторон? В таком случае цель PCA и факторного анализа – выявить эту скрытую переменную.



Этапы проведения РСА


- 1) Стандартизация переменных

Этапы проведения PCA

- 1) Стандартизация переменных
- 2) Расчет матрицы ковариаций


Этапы проведения PCA

- 1) Стандартизация переменных
- 2) Расчет матрицы ковариаций
- 3) Вычисление собственных векторов (eigenvectors) и собственных значений (eigenvalues) ковариационной матрицы



Этапы проведения PCA

- 1) Стандартизация переменных
- 2) Расчет матрицы ковариаций
- 3) Вычисление собственных векторов (eigenvectors) и собственных значений (eigenvalues) ковариационной матрицы
- 4) Определение числа компонент (собственные значения больше 1)









Этапы проведения PCA

- 1) Стандартизация переменных
- 2) Расчет матрицы ковариаций
- 3) Вычисление собственных векторов (eigenvectors) и собственных значений (eigenvalues) ковариационной матрицы
- 4) Определение числа компонент
- 5) Расчет главных компонент на основе исходных переменных (**все** исходные переменные участвуют в расчете значений компонент)

$$PCA_1 = a_1x_1 + a_2x_2 + \dots + a_nx_n$$
$$PCA_2 = b_1x_1 + b_2x_2 + \dots + b_nx_n$$

РСА наглядно




Факторный анализ

- Факторный анализ позволяет снизить размерность данных, путем сведения большого числа переменных к меньшему числу факторов.
- Задача: найти такие комплексные факторы, которые наиболее полно объясняют дисперсию исходных данных
- Эксплораторный и конфирматорный факторный анализ

Этапы проведения PCA

- 1) Стандартизация переменных
- 2) Расчет матрицы ковариаций
- 3) Вычисление собственных векторов (eigenvectors) и собственных значений (eigenvalues) ковариационной матрицы
- 4) Определение числа компонент
- 5) Расчет главных компонент



Этапы проведения факторного анализа

- 1) Оценка применимости ФА к данным (критерий КМО)
- 2) Стандартизация исходных переменных
- 3) PCA
- 4) Вращение факторов
- 5) Интерпретация факторов

Критерий КМО и критерий Бартлетта

- **Критерий адекватности выборки Крайзера-Мейера-Олкина** показывает, насколько корреляция между переменными может быть объяснена другими переменными (целесообразно ли к таким данным применять PCA / FA?)
- **Критерий Бартлетта:** отличается ли корреляционная матрица между переменными от единичной матрицы? (Действительно ли между переменными есть связь?)

KMO Value	Internal Consistency
$KMO \geq 0.9$	Excellent
$0.9 > KMO \geq 0.8$	Good
$0.8 > KMO \geq 0.7$	Acceptable
$0.7 > KMO \geq 0.6$	Questionable
$0.6 > KMO \geq 0.5$	Poor
$0.5 > KMO$	Unacceptable

Вращение факторов

- **Факторные нагрузки** – это корреляции между исходными переменными и факторами. В зависимости от того, с какими переменными (не)коррелирует фактор, будет меняться его смысл. Вращение факторов нужно для того, чтобы подобрать такие коэффициенты, чтобы как можно больше переменных коррелировало с одним фактором и не коррелировало с другими

Sorted Rotated Factor Loadings and Communalities

Variable	Factor1	Factor2	Factor3	Factor4	Factor5	Communality
Academic record	0.815	0.191	0.206	0.167	-0.135	0.789
Potential	0.785	0.268	0.186	0.126	-0.355	0.864
Experience	0.694	0.196	-0.048	0.290	-0.199	0.646
Self-Confidence	0.216	0.877	0.166	0.090	-0.162	0.878
Likeability	0.173	0.703	0.247	0.182	-0.248	0.680
Appearance	0.283	0.644	0.317	0.213	-0.047	0.643
Organization	0.097	0.315	0.864	0.070	-0.255	0.925
Communication	0.139	0.242	0.815	0.235	-0.197	0.835
Resume	0.267	0.297	0.104	0.899	-0.100	0.989
Letter	0.184	0.073	0.193	0.805	-0.208	0.768
Job Fit	0.372	0.228	0.231	0.210	-0.810	0.943
Company Fit	0.300	0.216	0.376	0.207	-0.729	0.853
Variance	2.2803	2.1752	1.9204	1.8175	1.6177	9.8111
% Var	0.190	0.181	0.160	0.151	0.135	0.818